

The logo for UNL (Universidad Nacional de La Plata) is a dark gray square with the letters "UNL" in white, bold, sans-serif font.The logo for FICH (Facultad de Ingeniería y Ciencias) is a blue square with the letters "FICH" in white, bold, sans-serif font.

Trabajo Práctico Creativo **2da entrega**

Nombres: Fontana Juan Pablo, Aguilar Valentin y Gasparutti Lucas

Fecha de entrega: 23/10/2025

Materia: Inteligencia Computacional

Profesor encargado: Leandro Di Persia

Introducción

Razones de Elección del Tema:

En los tiempos que corren, consideramos que un problema de gran importancia a resolver es el de la correcta clasificación de noticias falsas. Este tipo de noticias inundan los espacios cibernéticos, manipulando las ideas y el pensar de muchas personas mediante información errónea. Como estudiantes de ingeniería informática, nos parece importante desarrollar algoritmos que puedan clasificar correctamente que es información legítima y que no, para así lograr un internet de mayor calidad y evitar que sujetos caigan en ideas erróneas causadas por información falsa.

Además de la importancia a nivel social que solucionar este problema pueda implicar, también como estudiantes representa un desafío con el cual esperamos adquirir conocimientos sobre el estado del arte de la inteligencia computacional, introduciéndonos a temas como Tokenización, Embedding, Redes Convolucionales, Transformers, Ensamblados, etc.

También es importante aclarar, que como así mejoran los sistemas de detección de noticias falsas, mejoran los sistemas de escritura de noticias falsas, por lo cual incrementalmente se va volviendo un problema más difícil de resolver.

Búsqueda bibliográfica :

Se puede encontrar una gran variedad de estudios realizados intentando implementar una solución adecuada a esta problemática.

La bibliografía principal a seguir [1] utiliza una combinación entre CNN y RNN, creando un modelo híbrido que logra capturar tanto patrones textuales locales como también aplicar características contextuales del texto. Este modelo resultó tener una medida de exactitud (*accuracy*) del 91.80% con datos de test, lo cual se considera una medida alta y realista. Tanto el modelo como su bibliografía correspondiente nos pareció comprensible y realizable, por lo tanto se lo elige como guía a seguir, además de poseer un dataset accesible [2].

En el estudio [3] se aplicó el modelo XGBoost para estimar la importancia de cada variable, para derivar los factores de prioridad que preferentemente afectan a la detección de fake news. Basado en esas variables se utilizaron los modelos de clasificación SVM, RF, LR, CART, y RNN. El mejor modelo fue el Random Forest con un 94% de tasa de predicción, y el peor fue la red neuronal con un 92.1%. Este estudio tiene la peculiaridad de utilizar un dataset propio que tenía en cuenta factores “sociales”, obtenidos a través de un análisis en la red social [X.com](#). Este estudio también se toma de referencia para analizar ciertas características del problema a resolver.

Se pueden mencionar también otros trabajos realizados sobre el tema que analizan otras alternativas, como la utilización de ensambles con soft voting combinando modelos como SVM, RF, XGB, etc. [4], o trabajos en donde se realizan una exploración y armado más detallado de un dataset [5], los cuales se toman como referencia puntual pero no como guía ya que se encontraron inconsistencias (como tasas de acierto poco realistas), datasets inaccesibles o utilización de métodos que escapan a los alcances de este trabajo.

Metodología

La metodología propuesta es la siguiente:

- **1. Colección de datos:** En este caso ya disponemos de un dataset público [2] con noticias falsas y noticias verdaderas, correctamente clasificadas.

- **2. Preprocesamiento de datos:** Hay datos incompletos y ruido, por lo que trabajar con los datos antes es crucial.
- **3. Análisis de datos:** Se grafican histogramas con la frecuencia de palabras, estas se llaman 'word clouds' y se utilizan comúnmente para entender las palabras significantes en un dataset. Esto permite realizar una exploración previa de los datos, anterior a entrenar el modelo.
- **4. Feature Engineering (Ingeniería de Características):** Paso crucial para proveer al modelo de Machine Learning mayor poder representacional, cambiando datos crudos por características bien diseñadas que exponen patrones y asociaciones. Por lo que el procesamiento de lenguajes respecta, el proceso de ingeniería de características está expresado por la intención de encontrar representaciones importantes de los datos textuales.
 - **4.1 Dataset splitting:** Se separan los datos en datos de training y en datos de testing.
 - **4.2 Tokenización y Padding:** Se utilizará la librería 'Keras' para tokenizar el texto en formato 'Naives-1' que es una secuencia de números enteros. El padding es utilizado para hacer todas las secuencias de tokens de tamaño uniforme.
 - **4.3 Incrustación de palabras (Word Embedding):** Las 'word embeddings' se utilizan para capturar relaciones semánticas que existen entre las palabras dadas asignándoles coordenadas en vectores de altas dimensiones. Se utilizarán embeddings pre-entrenados (GloVe)
 - **4.4 Inicialización de Matriz de Embedding:** Cada fila es asignada a un índice de palabra en el vocabulario del tokenizador.
 - **4.5 Integración con el Tokenizer:** La matriz de embedding será integrada con el tokenizador para asegurarse que las palabras en el vocabulario sean mapeadas a su correcto vector de embedding durante el entrenamiento. Esta integración será útil para mejorar la captura de similitudes semánticas del texto.




Figura 1: Obtención de los vectores de embedding.

- **5. Implementación de la CNN:** Las redes convolucionales permiten capturar patrones locales de texto, es decir, identifica características en ventanas pequeñas de texto.




Figura 2: Ejemplo de red convolucional trabajando con texto.

- **6. Implementación de la RNN:** Las redes recurrentes tienen la capacidad de capturar características conceptuales del texto a nivel global, lo cual permite identificar dependencias a largo plazo. En este caso, se utilizará un LSTM.
- **7. Implementación de la arquitectura híbrida CNN-RNN [1].**
- **8. Ajuste de parámetros y selección del modelo apropiado :** Para encontrar un modelo apropiado, es necesario probar modelos con distintas combinaciones de parámetros y medir el desempeño de este, intentando llegar a una arquitectura que brinde una tasa de acierto aceptable.

Bibliografía:

- 1: *Detection of Fake News by Convolutional Neural Networks and Recurrent Neural Networks*. Subhranil Das, Rashmi Kumari, Raghwendra Kishore Singh.
<https://www.sciencedirect.com/science/article/pii/S1877050925015844>
- 2 : <https://www.kaggle.com/datasets/pathumveyron24/sherlockfakenewsnetorigins>
- 3: *Constructing a User-Centered Fake News Detection Model by Using Classification Algorithms in Machine Learning Techniques*. Minjung Park, Sangmi Chai.
<https://ieeexplore.ieee.org/document/10179862>
- 4: *Fake News Detection: Exploring the Efficiency of Soft and Hard Voting Ensemble*. Arifur Rahmana*, Sakib Zamana, Shahriar Parveja, Pintu Chandra Shilla, Md. Shahidul Salima, Dola Das. [Fake News Detection: Exploring the Efficiency of Soft and Hard Voting Ensemble - ScienceDirect](https://www.sciencedirect.com/science/article/pii/S1877050925015844)
- 5: *WELFake: Word Embedding Over Linguistic Features for Fake News Detection*. Pawan Kumar Verma, Member, IEEE, Prateek Agrawal, Ivone Amorim, and Radu Prodan
<https://ieeexplore.ieee.org/document/9395133>